Tarea M25

Adriana Rangel Martínez

Para este análisis se transforman las variables cualitativas a cuantitativas.

Primeramente, las variables de X, que en este caso son Sex, BP y Cholesterol. Esto se hace mediante el siguiente código.

```
from sklearn import preprocessing
Cod_Sex=preprocessing.LabelEncoder()
Cod_Sex.fit(['F','M'])
X[:,1]=Cod_Sex.transform(X[:,1])
Cod_BP=preprocessing.LabelEncoder()
Cod_BP.fit(['LOW','NORMAL','HIGH'])
X[:,2]=Cod_BP.transform(X[:,2])
Cod_Cholesterol=preprocessing.LabelEncoder()
Cod_Cholesterol.fit(['NORMAL','HIGH'])
X[:,3]=Cod_Cholesterol.transform(X[:,3])
```

Después la variable que conforma a y, referente al tipo de medicamento también se transforma a cuantitativa. Dando como resultado el conjunto de elementos numéricos que se muestra.

```
Cod_drug=preprocessing.LabelEncoder()
Cod_drug.fit(['drugA','drugB','drugC','drugX','drugY'])
y=Cod_drug.transform(y)
y
```

```
array([4, 2, 2, 3, 4, 3, 4, 2, 4, 4, 2, 4, 4, 4, 3, 4, 3, 0, 2, 4, 4, 4,
       4, 4, 4, 4, 4, 3, 4, 4, 3, 1, 3, 4, 3, 3, 0, 3, 3, 3, 4, 1, 4, 3,
       3, 3, 0, 2, 4, 4, 4, 3, 4, 4, 1, 2, 1, 4, 3, 4, 4, 0, 4, 3, 1, 4,
       0, 3, 4, 4, 1, 4, 3, 4, 4, 4, 0, 4, 0, 3, 1, 3, 2, 0, 2, 1, 3, 4,
       4, 4, 4, 4, 4, 4, 4, 3, 4, 4, 4, 4, 0, 0, 2, 3, 4, 3, 3, 4, 1, 4,
       0, 3, 3, 3, 3, 4, 3, 3, 0, 4, 4, 4, 4, 4, 1, 4, 4, 3, 4, 3, 4, 4,
       3, 4, 4, 3, 1, 0, 1, 3, 0, 4, 1, 4, 0, 3, 3, 0, 3, 2, 0, 1, 3, 3,
       4, 2, 0, 4, 2, 3, 3, 1, 3, 4, 4, 4, 4, 3, 4, 0, 3, 3, 4, 4, 0, 4,
       0, 4, 4, 4, 4, 3, 3, 4, 4, 4, 1, 0, 4, 4, 4, 0, 4, 2, 4, 2, 2, 3,
       3, 3])
```

SAG

El primer método de optimización utilizado es la regresión logística con solucionador SAG. Con este modelo los interceptos de cada una de las 5 variables que conforman a X y sus respectivos pesos son:

```
Interceptos (Beta's 0) [ 0.25026859 -0.08239889  0.08592635  0.29025542 -0.54405148]
```

```
Pesos de cada variable (Beta1, Beta2, Beta3, Beta4,...,Beta7) [[-0.02657697  0.15952679 -0.64234441  0.05543718
0.10038879]
 [ 0.07165169 -0.04694539 -0.62562829 -0.01075835 -0.27727682]
 [-0.00372802  0.01182145  0.14471152 -0.271361   -0.01617896]
 [ 0.00988675 -0.0444057   1.29310297  0.42358674 -0.11667839]
 [-0.05123344 -0.07999716 -0.16984179 -0.19690457  0.30974537]]
```

Y los estadísticos de presicion obtenidos son:

```
              precision    recall  f1-score   support

       drugA       0.00      0.00      0.00         4
       drugB       0.33      1.00      0.50         2
       drugC       0.00      0.00      0.00         4
       drugX       0.79      0.85      0.81        13
       drugY       0.75      0.88      0.81        17

    accuracy                           0.70        40
   macro avg       0.37      0.55      0.43        40
weighted avg       0.59      0.70      0.63        40
```

Es decir que la presición global es del 70%, que no se oye tan mal, sin embargo se tienen grandes deficits para predecir los medicamentos C y A con un f1 score del 0.0%, con lo que el modelo es pésimo para predecir estos medicamentos y en general no funciona para este conjunto de datos.

Asi mismo se revisaron los métodos con solucionadores liblinear, saga, lbfgs pero se encontró que el solucionador con los mejores resultados fue el de Newton CG.

Newton CG

El segundo método de optimización utilizado es la regresión logística con solucionador Newton CG. Con este modelo los interceptos de cada una de las variables que conforman X y sus respectivos pesos son:

```
Interceptos (Beta's 0): [ 14.92976199   0.87908757  10.25648146   6.24457579 -32.30990681]
Pesos (Betas): [[-8.96134010e-02  3.54932114e-02 -2.31758678e+00 -4.79055897e-01
  -6.88039997e-01]
 [ 1.24913652e-01 -6.72354768e-02 -1.72769777e+00  8.90285979e-02
  -4.39123058e-01]
 [-2.62172391e-02 -8.10888848e-02  5.55542621e-01 -1.49469606e+00
  -6.08745568e-01]
 [-6.10393797e-03 -3.06446692e-01  3.07000041e+00  1.74859708e+00
  -5.84061756e-01]
 [-2.97915655e-03  4.19277840e-01  4.19741515e-01  1.36126279e-01
   2.31997031e+00]]
```

Con estadísticos de presición

```
              precision    recall  f1-score   support

           0       1.00      1.00      1.00         4
           1       0.50      1.00      0.67         2
           2       1.00      0.50      0.67         4
           3       1.00      1.00      1.00        13
           4       1.00      1.00      1.00        17

    accuracy                           0.95        40
   macro avg       0.90      0.90      0.87        40
weighted avg       0.97      0.95      0.95        40
```

Lo cual sugiere una gran mejora con respecto a los otros solucionadores pues la presición global es del 95% y los f1-score de todos los medicamentos están por encima del 50%. Especialmente para los medicamentos A, X y Y los f1 score son del 100%.

Curva ROC

En este caso como el modelo es multivariable se agregó un ciclo for para que se generara una curva ROC para cada medicamento y así poder ver la relación entre los verdaderos positivos y falsos positivos para cada uno. En este caso al cambiar la variable “Drug” a variable numérica se hizo la siguiente relación:

DrugA = 0
DrugB = 1
DrugC = 2
DrugX = 3
DrugY = 4

El codigo utilizado fue el siguiente:

```
from sklearn.metrics import roc_curve
from sklearn.metrics import roc_auc_score
#fpr = false positive rate
#tpr= true positive rate
# thresholds= limites para valores de p
for i in range(y_test_bin.shape[1]):  # Para cada etiqueta
    fpr, tpr, thresholds = roc_curve(y_test_bin[:, i], y_pred_probs[:, i])
    auc = roc_auc_score(y_test_bin[:, i], y_pred_probs[:, i])
    print(f"AUC para la etiqueta {i}: {auc}")
    plt.plot([0,1],[0,1],'k--')
    plt.plot(fpr,tpr,marker='.',label=f"curva ROC (area=%0.2f) {i}"%  auc)
    plt.xlabel("tasa de falsos positivos")
    plt.ylabel("tasa de verdaderos positivos")
    plt.legend(loc="lower right")
    plt.title("Curva de ROC para regresion logistica")
```

Y la curva ROC obtenida fue

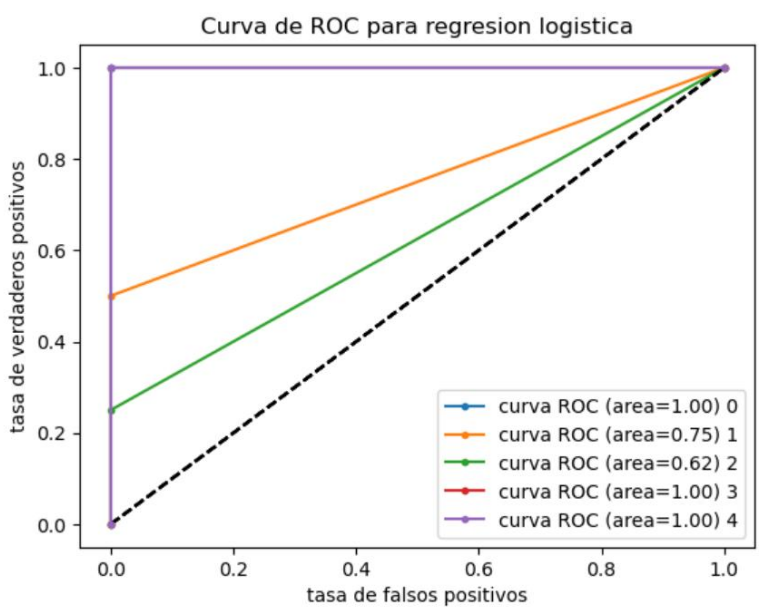

Lo que demuestra que la tasa de verdaderos positivos de 0(A),3(X) y 4(Y) es uno, es decir que todos los positivos que se pronosticaron fueron acertados. Mientra que para 1(B), el área bajo la curva fue de 0.75, lo que iplica que sigue siendo un alto número de pronósticos correctos, pero no es tan confiqable el modelo para pronosticar positivos de este medicamento. Para 2(C) el área es aún más baja por lo que tampoco es tan confiable el modelo para pronosticar la receta de este edicamento. Aunque tiene un punto débil en el pronostico del medicamento 2(C) en general el modelo con solucionador SG tiene muy buenos resultados.